

PENJELASAN DETAIL

Penggunaan 9 Fitur Terbaik untuk Memprediksi Survival_Prediction

Topik	Prediksi Kanker Kolorektal dengan 9 Fitur + SMOTE
Target	Survival_Prediction (Yes=60%, No=40%)
Algoritma	SVM, XGBoost, Random Forest, KNN
Teknik	SMOTE K=5, StandardScaler, One-Hot Encoding

BAB 1: RINGKASAN PROSES

Proses prediksi Survival_Prediction menggunakan 9 fitur terbaik dilakukan dalam 6 tahapan utama:

Tahap	Langkah	Deskripsi
1	Feature Selection	Pilih 9 fitur terbaik dari 47 fitur via 3 metode (RF, MI, Chi-Square)
2	One-Hot Encoding	Ubah 4 fitur kategorikal jadi numerik (9 fitur → 11 fitur)
3	Split + SMOTE	80/20 train/test split + SMOTE K=5 untuk balance kelas (60%→50%)
4	StandardScaler	Normalisasi Z-Score agar semua fitur punya skala sama
5	Training	Latih 4 algoritma: SVM, XGBoost, Random Forest, KNN
6	Evaluasi	Confusion Matrix, ROC-AUC, F1-Score, Precision, Recall

BAB 2: PEMILIHAN 9 FITUR TERBAIK

Dari total 47 fitur hasil One-Hot Encoding, dipilih 9 fitur terbaik berdasarkan konsensus 3 metode feature selection: Random Forest Importance, Mutual Information, dan Chi-Square Test.

2.1 5 Fitur Numerik

No	Fitur	Tipe	Rank RF	Alasan
1	Healthcare_Expense_per_person	Numerik	#1 (0.1417)	kompleksitas penanganan kanker. Semakin tinggi biaya, semakin kompleks ka
2	Age	Numerik	#2 (0.0956)	usia adalah faktor utama kanker kolorektal. Insiden meningkat tajam setelah usia 50 tahun
3	Tumor_Size_mm	Numerik	#3 (0.093)	tumor berkorelasi dengan agresivitas dan stadium kanker
4	Incidence_Rate	Numerik	#4 (0.0871)	tingkat insiden di populasi mencerminkan prevalensi kanker
5	Mortality_Rate	Numerik	#5 (0.0761)	tingkat mortalitas sebagai indikator prognosis populasi

2.2 4 Fitur Kategorikal

No	Fitur	Kategori	Metode	Alasan Medis
6	Alcohol_Consumption	Yes/No	Konsensus	konsumsi alkohol meningkatkan risiko kanker kolorektal 1.2-1.5x
7	Diet_Risk	Low/Mod/High	Konsensus	Diet tinggi lemak dan daging merah merupakan faktor risiko utama
8	Economic_Class	Dev/Developing	Konsensus	Negara maju punya akses screening lebih baik
9	Healthcare_Access	Good/Mod/Poor	Konsensus	Akses kesehatan mempengaruhi deteksi dini dan kualitas treatment

BAB 3: ONE-HOT ENCODING

Algoritma machine learning hanya dapat memproses data numerik. Fitur kategorikal harus diubah ke format numerik melalui One-Hot Encoding.

3.1 Proses Encoding

One-Hot Encoding mengubah setiap kategori menjadi kolom biner (0 atau 1). Contoh:

```
Alcohol_Consumption = 'Yes' → Alcohol_Consumption_Yes = 1  
Alcohol_Consumption = 'No' → Alcohol_Consumption_Yes = 0  
  
Diet_Risk = 'Low' → Diet_Risk_Low = 1, Diet_Risk_Moderate = 0  
Diet_Risk = 'Moderate' → Diet_Risk_Low = 0, Diet_Risk_Moderate = 1  
Diet_Risk = 'High' → Diet_Risk_Low = 0, Diet_Risk_Moderate = 0 (keduanya 0 = High)
```

3.2 Hasil Encoding

9 fitur asli setelah One-Hot Encoding menjadi 11 fitur numerik:

No	Nama Fitur	Sumber
1	Age	Fitur asli
2	Tumor_Size_mm	Fitur asli
3	Healthcare_Costs	Fitur asli
4	Incidence_Rate_per_100K	Fitur asli
5	Mortality_Rate_per_100K	Fitur asli
6	Alcohol_Consumption_Yes	Encoding Alcohol_Consumption
7	Diet_Risk_Low	Encoding Diet_Risk
8	Diet_Risk_Moderate	Encoding Diet_Risk
9	Economic_Classification_Developing	Encoding Economic_Classification
10	Healthcare_Access_Moderate	Encoding Healthcare_Access
11	Healthcare_Access_Poor	Encoding Healthcare_Access

BAB 4: SMOTE OVERSAMPLING K=5

SMOTE (Synthetic Minority Over-sampling Technique) digunakan untuk mengatasi ketidakseimbangan kelas pada target Survival_Prediction.

4.1 Masalah Imbalance

Kelas	Jumlah	Persentase
Yes (Survive)	18.014	60.0%
No (Tidak)	11.986	40.0%

Tanpa SMOTE, model akan selalu memprediksi "Yes" karena dengan begitu akurasi sudah 60%. Model menjadi "malas" dan tidak belajar membedakan kelas.

4.2 Cara Kerja SMOTE

SMOTE bekerja dengan membuat sampel sintetik untuk kelas minoritas (No) berdasarkan tetangga terdekatnya:

1. Ambil sampel dari kelas minoritas (No)
2. Cari K=5 tetangga terdekat (berdasarkan jarak Euclidean)
3. Buat sampel baru di antara titik asli dan tetangganya
4. Ulangi sampai jumlah kelas minoritas = kelas mayoritas

4.3 Hasil SMOTE

Metrik	Sebelum SMOTE	Setelah SMOTE
Jumlah Yes	14.384 (60%)	14.384 (50%)
Jumlah No	9.616 (40%)	14.384 (50%)
Total Train	24.000	28.768 (+4.768)

Efek SMOTE: Recall SVM turun dari 1.0 (curang) menjadi 0.62 (realistis). Model sekarang benar-benar belajar membedakan Yes dan No.

BAB 5: STANDARD SCALER

StandardScaler melakukan normalisasi Z-Score pada fitur numerik agar semua fitur memiliki skala yang sama (mean=0, std=1).

5.1 Kenapa Scaling Diperlukan?

Fitur numerik memiliki rentang nilai yang sangat berbeda:

Fitur	Rentang	Mean	Std
Age	40 - 99	68.65	14.38
Tumor_Size_mm	1 - 100	50.07	28.91
Healthcare_Costs	25.000 - 120.000	72.452	27.404

Algoritma SVM dan KNN berbasis jarak (Euclidean distance). Tanpa scaling, Healthcare_Costs (skala 25.000-120.000) akan mendominasi perhitungan jarak dibandingkan Age (skala 40-99).

5.2 Rumus Z-Score

$$X_{\text{scaled}} = (X - \text{mean}) / \text{std}$$

Setelah scaling, semua fitur memiliki mean=0 dan standar deviasi=1, sehingga kontribusi setiap fitur dalam perhitungan jarak menjadi setara.

BAB 6: TRAINING 4 ALGORITMA

Empat algoritma machine learning dilatih untuk membandingkan performa:

Algoritma	Cara Kerja	Data Input	Keunggulan
SVM	Cari hyperplane pemisah	Scaled	Bagus untuk data dimensi tinggi
XGBoost	Ensemble tree bertahap	Original	Akurasi tinggi, handling missing values
Random Forest	Kumpulan decision tree	Original	Robust, tidak mudah overfit
KNN	Berdasarkan K tetangga terdekat	Scaled	Sederhana, non-parametrik

6.1 Hasil Training

Model	Accuracy	Precision	Recall	F1-Score	ROC-AUC
Random Forest	0.5490	0.6022	0.7294	0.6597	0.4938
XGBoost	0.5368	0.6053	0.6532	0.6283	0.5000
SVM	0.5277	0.6026	0.6221	0.6122	0.4993
KNN	0.5132	0.6019	0.5542	0.5771	0.5034
Baseline	0.4007	0.0000	0.0000	0.0000	0.5000


6.2 Analisis Hasil

- Random Forest** memiliki F1-Score tertinggi (0.6597) dan Recall tertinggi (0.7294) — artinya Random Forest paling baik dalam menangkap pasien yang benar-benar survive.
- XGBoost** memiliki Precision tertinggi (0.6053) — dari semua yang diprediksi survive, 60.53% benar-benar survive.
- SVM** dan **KNN** memiliki performa lebih rendah karena dataset ini mungkin tidak linearly separable.
- ROC-AUC semua model ~0.5** — ini menunjukkan bahwa fitur yang digunakan tidak memiliki daya pembeda yang cukup antara kelas Yes dan No.

BAB 7: CONFUSION MATRIX

Confusion Matrix menunjukkan perbandingan antara prediksi model dengan aktual:


CONFUSION MATRIX - Perbandingan Algoritma



7.1 Interpretasi

Confusion Matrix terdiri dari 4 sel:

- **TN (True Negative):** Model benar memprediksi "Tidak Survive"
- **FP (False Positive):** Model salah memprediksi "Survive" (padahal tidak)
- **FN (False Negative):** Model salah memprediksi "Tidak Survive" (padahal survive)
- **TP (True Positive):** Model benar memprediksi "Survive"



BAB 8: KESIMPULAN

8.1 Keberhasilan

1. **SMOTE berhasil** mengatasi masalah class imbalance. Recall SVM turun dari 1.0 (model curang) menjadi 0.62 (realistis).
2. **9 fitur terbaik** cukup representatif — hasilnya setara dengan menggunakan 47 fitur (lebih efisien dan mengurangi noise).
3. **Random Forest** menjadi algoritma terbaik dengan F1-Score 0.6597.
4. **Pipeline preprocessing** berjalan dengan benar: encoding → SMOTE → scaling.

8.2 Keterbatasan

1. **ROC-AUC semua model ~0.5** — fitur di dataset tidak memiliki sinyal prediktif yang cukup untuk memprediksi Survival_Prediction.
2. Dataset ini kemungkinan besar **bersifat sintetik** (0 missing values, 0 outliers, semua fitur independen satu sama lain).
3. Bahkan dengan Neural Network, PCA, Stacking, dan GridSearch — hasil tetap AUC ~0.5.

8.3 Rekomendasi

1. Verifikasi sumber dataset — pastikan data berasal dari sumber resmi (bukan sintetik).
2. Cari dataset tambahan dengan fitur klinis riil (biomarker, TNM staging, histopatologi).
3. Gunakan dataset ini untuk analisis statistik deskriptif — sangat cocok untuk EDA.